This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the version available on IEEE Xplore.

挤压与激励网络

杰华[1*]
hujie@momenta.ai
[1] Momenta

李森[2*]
lishen@robots.ox.ac.uk
[2] 牛津大学工程科学系

孙刚[1]
sungang@momenta.ai

摘要

卷积神经网络建立在卷积操作之上，该操作通过在局部感受野内融合空间信息和通道信息来提取 informative 特征。为了提升网络的代表性能力，近期的一些方法展示了增强空间编码的优势。在本工作中，我们关注通道关系，并提出了一种新颖的架构单元，我们称之为"Squeeze- and-Excitation"（SE）模块块，该模块通过显式建模通道间的相互依赖关系，自适应地重新校准通道特征响应。我们证明，通过堆叠这些模块块，可以构建 SENet 架构，这些架构在具有挑战性的数据集上泛化能力极强。关键的是，我们发现 SE 模块块以极小的额外计算成本，为现有的最先进深度架构带来了显著的性能提升。由 SENet 构成的架构构成了我们 ILSVRC 2017 分类提交的基石，该提交获得第一名，并将 top-5 错误率显著降低至 2.251%，相对于 2016 年获胜者的 2.251% 实现了 ∼25% 的相对提升。代码和模型可在 https: // github.com/hujie-frank/SENet 获取。

1. 简介

卷积神经网络（CNNs）已被证明是解决多种视觉任务的有效模型[21, 27, 33, 45]。对于每一层卷积层，都会学习一组滤波器，以表达输入通道上的局部空间连接模式。换句话说，卷积滤波器预期是融合局部感受野内空间信息和通道信息的组合。通过堆叠一系列交替包含非线性激活和降采样操作的卷积层，CNNs 能够捕捉具有全局感受野的层次化模式，从而作为强大的图像描述。最近的研究表明，通过显式嵌入学习可以改进网络性能有助于在不需额外监督的情况下捕捉空间相关性的机制。其中一种方法由 Inception 架构 [16, 43]，推广开来，该架构表明网络可以通过在模块中嵌入多尺度过程来实现具有竞争力的准确率。最近的工作致力于更好地建模空间依赖 [1, 31] 并融入空间注意力 [19]。

本文研究了架构设计的一个不同方面——通道关系，通过引入一种新的架构单元，我们将其称为" Squeeze-and-Excitation"（SE）块。我们的目标是通过显式建模卷积特征之间通道的相互依赖关系，来提升网络的表征能力。为此，我们提出了一种机制，使网络能够执行特征重校准，从而学会利用全局信息有选择地强调 informative 特征并抑制较不重要的特征。

图 1 展示了 SE 构建块的基本结构。对于任意给定的变换 $F_{tr}: X \rightarrow U, X \in \mathbb{R}^{H' \times W' \times C'}, U \in \mathbb{R}^{H \times W \times C}$（例如一个卷积层或一组卷积层），我们可以构建一个对应的 SE 块来进行特征重校准，具体步骤如下。首先，特征 U 通过一个 squeeze 操作，将特征图在空间维度 $H \times W$ 上进行聚合，生成通道描述符。该描述符嵌入了通道级特征响应的全局分布，使得网络的全局感受野信息能够被其下层利用。随后进行 excitation 操作，其中基于通道依赖性的自门控机制为每个通道学习到的样本特定激活值，控制每个通道的激活。最后，对特征图 U 进行重新加权以生成 SE 块的输出，该输出可直接输入到后续层中。

一个 SE 网络可以通过简单地堆叠一组 SE 构建模块来生成。SE 模块块也可用作架构中任意深度的原始模块的即插即用替代品。然而，虽然构建模块的模板是通用的，正如我们在第 6.4 节所示，它在不同深度所扮演的角色会适应网络的需求。在早期层中，它学会激发具有信息量的

*同等贡献。

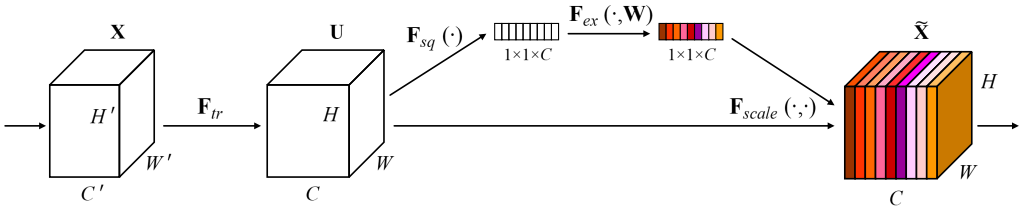


图 1：一个挤压 - 激励块。

以与类别无关的方式提取特征，提升共享底层表示的质量。在后续层中，SE 模块块变得日益专业化，并以高度类别特定的方式响应不同输入。因此，SE 模块块所进行的特征重校准带来的益处可贯穿整个网络进行累积。

新 CNN 架构的开发是一项具有挑战性的工程任务，通常涉及选择大量新的超参数和层配置。相比之下，上述 SE 模块的设计简单，可直接用于现有的最先进架构，其模块可通过直接用 SE 模块替换来增强。

此外，如第 4 节所示，SE 模块块计算轻量，仅轻微增加模型复杂度和计算负担。为支持这些主张，我们开发了多种 SENet，并在 ImageNet 2012 数据集 [34] 上进行了广泛评估。为展示其通用适用性，我们还提供了超越 ImageNet 的结果，表明所提出的方法并不局限于特定数据集或任务。

使用 SENet，我们在 ILSVRC 2017 分类竞赛中荣获第一名。我们的最佳模型集成在测试集[1]上实现了 2.251% 的 top-5 错误率。与去年获奖作品（top-5 错误率为 2.991%）相比，这代表了 ∼25% 的相对提升。

2. 相关工作

深度架构。VGGNet [39] 和 Inception 模块[43] 证明了增加深度的益处。批归一化（BN） [16] 通过插入单元来调节层输入，改善了梯度传播，稳定了学习过程。ResNet [10, 11] 展示了通过基于恒等映射的跳跃连接学习更深层网络的有效性。Highway 网络 [40]采用门控机制来调节捷径连接。对网络层之间连接的重新设计[5, 14] 已被证明能进一步提升深度网络的学习能力和表征特性。

另一种研究途径探索了调整网络模块化组件的功能形式的方法。分组卷积可用于增加卷积层维数（变换集合的大小） [15, 47]。多分支卷积可被视为该概念的一种泛化，能够支持更灵活的算子组合 [16, 42, 43, 44]。最近，以自动化方式学习的组合 [26, 54, 55] 已展现出具有竞争力的性能。跨通道相关性通常被映射为特征的新组合，这些组合要么独立于空间结构 [6, 20] ，要么通过标准卷积滤波器 [24] 与 1×1 卷积联合使用。该领域的大部分工作集中于降低模型和计算复杂度，这反映了这样一种假设：通道关系可以表述为具有局部感受野的实例无关函数的组合。相比之下，我们认为，为单元提供一种机制，利用全局信息显式建模通道间动态非线性依赖关系，可以简化学习过程，并显著提升网络的表征能力。

注意力机制与门控机制。注意力机制广义上可被视为一种工具，用于将可用的处理资源偏向分配给输入信号中最具信息量的组成部分 [17, 18, 22, 29, 32]。此类机制的优势已在多项任务中得到验证，涵盖图像中的定位与理解 [3, 19] 以及基于序列的模型 [2, 28]。它通常与门控函数（例如 softmax 或 sigmoid）及序列技术 [12, 41] 结合使用。近期研究已表明其适用于图像描述 [4, 48] 和唇语识别 [7] 等任务。在这些应用中，它常被叠加在一层或多层之上，这些层代表更高层级的抽象，用于模态间的适配。Wang 等人 [46] 提出了一种强大的主干与掩码注意力机制，该机制利用沙漏模块 [31]。该高容量单元被插入深度残差网络的中间阶段之间。相比之下，我们提出的 SE 模块是一种轻量级门控机制，专门用于以计算高效的方式建模通道间关系，并旨在增强网络中基础模块的表征能力。

3. 挤压 - 激励块

挤压 - 激励块是一种计算单元，可用于构建任意给定的变换 $\mathbf{F}_{tr}: \mathbf{X} \rightarrow \mathbf{U}, \mathbf{X} \in \mathbb{R}^{H' \times W' \times C'}, \mathbf{U} \in \mathbb{R}^{H \times W \times C}$。对于

[1] http://image-net.org/challenges/LSVRC/2017/results

简洁性：在随后的记号中，我们将 F_{tr} 视为一个卷积算子。令 $\mathbf{V} = [\mathbf{v}_1, \mathbf{v}_2, \ldots, \mathbf{v}_C]$ 表示学习到的滤波器核集合，其中 v_c 指代第 c 个滤波器的参数。我们可以将 $\mathbf{F}_{tr}$ as $\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \ldots, \mathbf{u}_C]$ 的输出写为，其中

$$\mathbf{u}_c = \mathbf{v}_c * \mathbf{X} = \sum_{s=1}^{C'} \mathbf{v}_c^s * \mathbf{x}^s. \tag{1}$$

其中 $*$ 表示卷积，$\mathbf{v}_c = [\mathbf{v}_c^1, \mathbf{v}_c^2, \ldots, \mathbf{v}_c^{C'}]$ 和 $\mathbf{X} = [\mathbf{x}^1, \mathbf{x}^2, \ldots, \mathbf{x}^{C'}]$（为简化符号，省略偏置项），而 v_c^s 是一个 2D 空间核，因此代表 v_c 的一个通道，作用于 X 的对应通道。由于输出是通过所有通道的求和产生的，通道依赖性隐式地嵌入在 v_c 中，但这些依赖与滤波器捕获的空间相关性纠缠在一起。我们的目标是确保网络能够增强对信息特征的感受性，以便后续变换加以利用，同时抑制那些不太有用的特征。我们提出通过显式建模通道间依赖关系，在将其送入下一个变换之前，分两步（挤压和激励）重新校准滤波器响应。SE 构建块的示意图如图 1 所示。

3.1. Squeeze：全局信息嵌入

为了解决利用通道依赖的问题，我们首先考虑输出特征中每个通道的信号。每个学习到的滤波器都使用局部感受野，因此变换输出 U 中的每个单元都无法利用该区域之外的上下文信息。这一问题在网络的下层尤为严重，因为下层的感受野尺寸较小。

为缓解该问题，我们提出将全局空间信息压缩为通道描述符。这通过使用全局平均池化来生成通道维度的统计信息来实现。形式上，一个统计量 $\mathbf{z} \in \mathbb{R}^C$ 是通过将 U 沿空间维度 $H \times W$ 压缩而生成的，其中 z 的第 c 个元素计算如下：

$$z_c = \mathbf{F}_{sq}(\mathbf{u}_c) = \frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} u_c(i, j). \tag{2}$$

讨论。变换输出 U 可被解释为局部描述符的集合，这些描述符的统计特性能够表征整张图像。利用此类信息在特征工程工作中十分普遍[35, 38, 49]。我们选择最简单的全局平均池化，当然也可以在此采用更复杂的聚合策略。

3.2. 激发：自适应重新校准

为了利用挤压操作中聚合的信息，我们随后执行第二个操作，该操作旨在以充分捕捉通道间的依赖关系。为实现这一目标，该函数需满足两个条件：首先，它必须具备灵活性（特别是能够学习通道间的非线性交互）；其次，它必须学习一种非互斥的关系，因为我们希望允许多个通道被强调，而非仅采用独热激活。为满足这些条件，我们选择采用一种简单的门控机制，并使用 Sigmoid 激活：

$$\mathbf{s} = \mathbf{F}_{ex}(\mathbf{z}, \mathbf{W}) = \sigma(g(\mathbf{z}, \mathbf{W})) = \sigma(\mathbf{W}_2 \delta(\mathbf{W}_1 \mathbf{z})), \tag{3}$$

其中 δ 指代 ReLU [30] 函数、$\mathbf{W}_1 \in \mathbb{R}^{\frac{C}{r} \times C}$ 和 $\mathbf{W}_2 \in \mathbb{R}^{C \times \frac{C}{r}}$。为限制模型复杂度并辅助泛化，我们通过在线性单元周围构建两个全连接（FC）层形成的瓶颈结构来参数化门控机制，即一个具有参数 W_1 且压缩比为 r 的降维层（该参数选择见第 6.4 节讨论），随后是一个 ReLU 层，再是一个具有参数 W_2 的升维层。该块的最终输出是通过将变换输出 U 与激活值进行缩放而获得的：

$$\widetilde{\mathbf{x}}_c = \mathbf{F}_{scale}(\mathbf{u}_c, s_c) = s_c \cdot \mathbf{u}_c, \tag{4}$$

其中 $\widetilde{\mathbf{X}} = [\widetilde{\mathbf{x}}_1, \widetilde{\mathbf{x}}_2, \ldots, \widetilde{\mathbf{x}}_C]$ 和 $\mathbf{F}_{scale}(\mathbf{u}_c, s_c)$ 指的是特征图 $\mathrm{u}_c \in \mathbb{R}^{H \times W}$ 与标量 s_c 之间的逐通道乘法。

讨论。激活值充当了适应于输入特定描述符 z 的通道权重。在这方面，SE 模块块内在引入了依赖于输入的动态性，有助于提升特征的可区分性。

3.3. 示例：SE Inception 和 SE ResNet

将 SE 模块块应用于 AlexNet[21] 和 VGGNet [39] 非常直接。SE 模块的灵活性意味着它可以直接应用于超越标准卷积的变换。为了说明这一点，我们将 SE 模块集成到具有复杂设计的现代架构中，从而开发 SENet。

对于非残差网络，例如 Inception 网络，SE 模块块是通过将变换 F_{tr} 设为整个 Inception 模块（见图 2）来构建的。通过在架构中的每个此类模块中做出这一更改，我们构建了一个 SE-Inception 网络。此外，SE 模块块具有足够的灵活性，可应用于残差网络。图 3 展示了 SE-ResNet 模块的架构。在此，SE 模块块的变换 F_{tr} 被设为残差模块的非恒等分支。Squeeze 和 excitation 均在与恒等分支求和之前执行。通过遵循类似的方案，可以构建更多与 ResNeXt [47], 、Inception-ResNet [42], 、MobileNet [13] 和 ShuffleNet [52] 集成的变体。表 1 描述了 SE-ResNet-50 和 SE-ResNeXt-50 的架构。

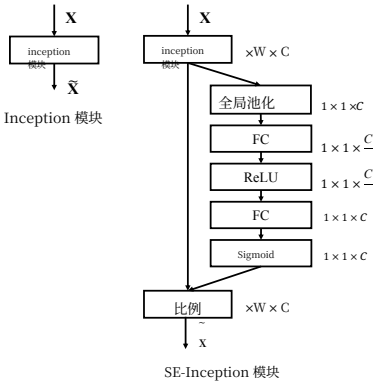


图 2：原始 inception 模块（左）和 SE-Inception 模块（右）的架构。

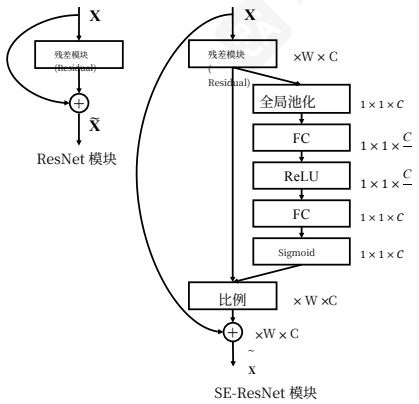


图 3：原始残差模块（左）与 SE-ResNet 模块（右）的架构示意图。

4. 模型与计算复杂度

为了使所提出的 SE 模块在实际应用中具有可行性，它必须在模型复杂度和性能之间提供有效的权衡，这对于可扩展性至关重要。我们在所有实验中都将缩减比例 r 设置为 16，除非另有说明（更多讨论见第 6.4 节）。为了说明该模块的成本，我们以 ResNet-50 与 SE-ResNet-50 的对比为例，其中 SE-ResNet-50 的精度优于 ResNet-50，并接近更深的 ResNet-101 网络的精度（见表 2）。ResNet-50 在单次前向传播中对 224×224 像素输入图像需要 ~3.86 GFLOPs。每个 SE 模块在压缩阶段使用全局平均池化操作，在激发阶段使用两个小型全连接层，随后进行廉价的通道级缩放操作。总体而言，SE-ResNet-50 需要 ~3.87 GFLOPs，相对于原始 ResNet-50 相对增加了 0.26%。

在实践中，使用 256 张图像的训练小批量，对 ResNet-50 进行单次前向和反向传播耗时 190 毫秒，而 SE-ResNet-50 为 209 毫秒（所有时间均在配备 8 张 NVIDIA Titan X GPU 的服务器上测量）。我们认为，考虑到现有的 GPU 库中全局池化和小型内积操作尚未得到充分优化，这一开销是合理的。此外，鉴于 SE 模块对嵌入式设备应用的重要性，我们还对每个模型进行了 CPU 推理时间的基准测试：对于 224×224 像素的输入图像，ResNet-50 耗时 164 毫秒，而 SE-ResNet-50 为 167 毫秒。SE 模块所需的小额额外计算开销，因其对模型性能的贡献而值得。

接下来，我们考虑所提出的模块引入的额外参数。所有这些参数都包含在门控机制的两个全连接层中，它们仅占网络总容量的很小一部分。更具体地说，引入的额外参数数量由下式给出：

$$\frac{2}{r}\sum_{s=1}^{S} N_s \cdot {C_s}^2 \tag{5}$$

其中 r 表示缩减比例，S 指代阶段数量（每个阶段指作用于具有相同空间维度的特征图的块集合），C_s 表示输出通道维度，N_s 表示阶段 s的重复块数量。SE-ResNet-50 在 ResNet-50 所需的 ~25 百万参数基础上增加了 ~2.5 百万参数，增幅为 ~10%。这些参数主要来自网络的最后阶段，该阶段在最大的通道维度上执行激励操作。然而，我们发现 SE 模块块的相对昂贵的最后阶段可以以微小的性能代价（ImageNet 上<0.1% top-1 错误率）移除，从而将相对参数增加量降低至 ~4%，这在参数使用是关键考量因素的情况下可能非常有用（详见第 6.4 节的进一步讨论）。

5. 实现

每个普通网络及其对应的 SE 变体均使用相同的优化方案进行训练。在 ImageNet 数据集上训练时，我们遵循标准做法，采用随机大小裁剪 [43]到 224×224 像素（299×299 针对 Inception-ResNet-v2[42]和 SE-Inception-ResNet-v2）以及随机水平翻转进行数据增强。输入图像通过均值通道减法进行归一化。此外，我们采用 [36]中描述的数据平衡策略用于小批量采样。网络在我们的分布式学习系统"ROCS"上进行训练，该系统专为处理大型网络的高效并行训练而设计。优化采用带动量 0.9 的同步 SGD，小批量大小为 1024。初始学习率设为 0.6，每 30 个 epoch 减少 10 倍。所有模型均进行训练

输出大小	ResNet-50	SE-ResNet-50	SE-ResNeXt-50 (32 × 4d)
112 × 112	卷积层, 7 × 7, 64, stride 2		
56 × 56	max pool, 3 × 3, stride 2		
	[卷积层 1 × 1, 64 卷积层 3 × 3, 64 卷积层 1 × 1, 256] × 3	[卷积层 1 × 1, 64 卷积层 3 × 3, 64 卷积层 1 × 1, 256 fc, [16, 256]] × 3	[卷积层 1 × 1, 128 卷积层 3 × 3, 128 卷积层 1 × 1, 256 fc, [16, 256] $C = 32$] × 3
28 × 28	[卷积层 1 × 1, 128 卷积层 3 × 3, 128 卷积层 1 × 1, 512] × 4	[卷积层 1 × 1 128 3 × 3 128 1 × 1 512 fc [32, 512]] × 4	[卷积层 1 × 1, 256 3 × 3, 256 卷积层 1 × 1, 512 fc, [32, 512] $C = 32$] × 4
14 × 14	[卷积层 1 × 1, 256 卷积层 3 × 3, 256 卷积层 1 × 1, 1024] × 6	[卷积层 1 × 1 256 3 × 3 256 1 × 1 1024 fc [64, 1024]] × 6	[卷积层 1 × 1 512 3 × 3 512 1 × 1 1024 fc [64, 1024] $C = 32$] × 6
7×7	[卷积层 1 × 1, 512 卷积层 3 × 3, 512 卷积层 1 × 1, 2048] × 3	[卷积层 1 × 1, 512 卷积层 3 × 3, 512 卷积层 1 × 1, 2048 fc, [128, 2048]] × 3	[卷积层 1 × 1 1024 3 × 3 1024 1 × 1 2048 fc [128, 2048] $C = 32$] × 3
1 × 1	全局平均池化, 1000 维 fc, softmax		

表 1: (左侧) ResNet-50。(中间) SE-ResNet-50。(右侧) 带有 32×4d 模板的 SE-ResNeXt-50。残差构建块的形状和特定参数设置的操作列在括号内，而各阶段中堆叠的块数列在括号外。SE 模块中两个全连接层之后的内括号表示输出维度。

	original		重新实现			SENet		
	Top-1 错误率	前 5 个错误率	top-1 错误率 (%)	前 5 个错误率	GFLOPs	Top-1 错误率	前 5 个错误率	GFLOPs
ResNet-50 [10]	24.7	7.8	24.80	7.48	3.86	$23.29_{(1.51)}$	$6.62_{(0.86)}$	3.87
ResNet-101 [10]	23.6	7.1	23.17	6.52	7.58	$22.38_{(0.79)}$	$6.07_{(0.45)}$	7.60
ResNet-152 [10]	23.0	6.7	22.42	6.34	11.30	$21.57_{(0.85)}$	$5.73_{(0.61)}$	11.32
ResNeXt-50 [47]	22.2	-	22.11	5.90	4.24	$21.10_{(1.01)}$	$5.49_{(0.41)}$	4.25
ResNeXt-101 [47]	21.2	5.6	21.18	5.57	7.99	$20.70_{(0.48)}$	$5.01_{(0.56)}$	8.00
VGG-16 [39]	-	-	27.02	8.81	15.47	$25.22_{(1.80)}$	$7.70_{(1.11)}$	15.48
BN-Inception [16]	25.2	7.82	25.38	7.89	2.03	$24.23_{(1.15)}$	$7.14_{(0.75)}$	2.04
Inception-ResNet-v2 [42]	$19.9^{\dagger}$	$4.9^{\dagger}$	20.37	5.21	11.75	$19.80_{(0.57)}$	$4.79_{(0.42)}$	11.76

表 2: 在 ImageNet 验证集上的单裁剪错误率（%）及复杂度对比。原始列指原始论文中报告的结果。为了进行公平比较，我们重新训练了基线模型，并在重新实现列中报告分数。SENet 列指添加了 SE 模块块的相应架构。括号中的数字表示相对于重新实现的基线的性能提升。 † 表示模型已在验证集的非黑名单子集上进行评估（详见 [42]），这可能会略微提高结果。VGG-16 和 SE-VGG-16 使用批量归一化进行训练。

从 100 个 epoch 开始，使用第 [9]节描述的权重初始化策略。

在测试时，我们在验证集上应用中心裁剪评估，其中 224×224 像素从每张图像中裁剪，每张图像的较短边首先被调整为 256（对于 Inception-ResNet-v2 和 SE-Inception-ResNet-v2，每张图像的较短边首先被调整为 352）。

6. 实验

6.1. ImageNet 分类

ImageNet 2012 数据集包含 1.28 亿张训练图像和来自 1000 个类别的 5 万张验证图像。我们在训练集上训练网络，并报告 top-1 和 top-5 错误率（%）。

网络深度。我们首先将 SE-ResNet 与不同深度的 ResNet 架构进行比较。表 2 的结果表明，SE 模块块在不同深度下始终能提升性能，同时计算复杂度的增加极小。

值得注意的是，SE-ResNet-50 在单裁剪下取得了 6.62% 的 top-5 验证误差，比 ResNet-50（7.48%）低 0.86%，并接近深度更深的 ResNet-101 网络（6.52% top-5 误差）所达到的性能，但计算开销仅为后者的 3.87 GFLOPs。

与 7.58 GFLOPs 相比）。这种模式在更深的网络中重复出现，其中 SE-ResNet-101（5 类错误率 6.07%）不仅与更深的 ResNet-152 网络（5 类错误率 6.34%）持平，而且性能高出 0.27 %。图 4 展示了 SE-ResNet-50 和 ResNet-50 的训练与验证曲线（

	原始		重新实现				SENet			
	top-1 错误率 (%) err.	top-5 err.	top-1 错误率 (%) err.	top-5 err.	MFLOPs	百万参数	top-1 错误率 (%) err.	top-5 err.	MFLOPs	百万参数
MobileNet [13]	29.4	-	29.1	10.1	569	4.2	$25.3_{(3.8)}$	$7.9_{(2.2)}$	572	4.7
ShuffleNet [52]	34.1	-	33.9	13.6	140	1.8	$31.7_{(2.2)}$	$11.7_{(1.9)}$	142	2.4

表 3：在 ImageNet 验证集上的单裁剪错误率（%）及复杂度对比。此处，MobileNet 指 [13] 中的"1.0 MobileNet-224"，ShuffleNet 指 [52] 中的"ShuffleNet $1\times(g=3)$"。

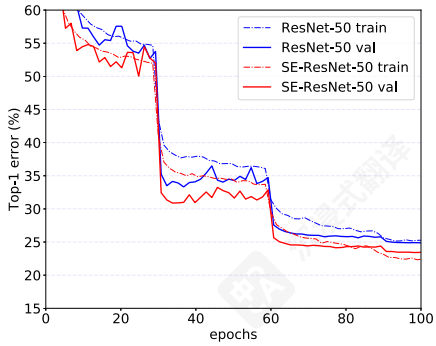


图 4：ResNet-50 和 SE-ResNet-50 在 ImageNet 上的训练曲线。

（更多网络的曲线见补充材料）。值得注意的是，SE 模块块本身会增加网络深度，但其计算效率极高，即使在基础架构深度扩展已出现边际效益递减的情况下，仍能获得良好的效果。此外，我们观察到，在不同深度的训练过程中，性能提升保持一致，这表明 SE 模块块带来的改进可以与基础架构深度的增加相结合使用。

	224×224		320×320 / 299×299	
	top-1 错误率 (%) err.	top-5 err.	top-1 错误率 (%) err.	top-5 err.
ResNet-152 [10]	23.0	6.7	21.3	5.5
ResNet-200 [11]	21.7	5.8	20.1	4.8
Inception-v3 [44]	-	-	21.2	5.6
Inception-v4 [42]	-	-	20.0	5.0
Inception-ResNet-v2 [42]	-	-	19.9	4.9
ResNeXt-101 (64×4d) [47]	20.4	5.3	19.1	4.4
DenseNet-264 [14]	22.15	6.12	-	-
注意力机制-92 [46]	-	-	19.5	4.8
Very Deep PolyNet [51] †	-	-	18.71	4.25
金字塔网络-200 [8]	20.1	5.4	19.2	4.7
DPN-131 [5]	19.93	5.12	18.55	4.16
SENet-154	**18.68**	**4.47**	**17.28**	**3.79**
NASNet-A (6@4032) [55] †	-	-	17.3‡	3.8‡
SENet-154（挑战后）	-	-	16.**88**‡	3.**58**‡

表 4：在 ImageNet 验证集上最先进的 CNN 的单裁剪错误率。测试裁剪的大小为 224×224 和 320×320/ 299×299，与 [11] 相同。 † 表示具有更大裁剪 331×331 的模型。 ‡ 表示挑战后的结果。SENet-154（挑战后）使用比原始输入大小 224×224 更大的输入大小 320×320 进行训练。

与现代化架构的集成。接下来，我们研究将 SE 模块块与另外两种最先进的架构——Inception-ResNet-v2 [42] 和 ResNeXt （采用 32×4d 设置） [47]，相结合的效果，这两种架构均在模块中引入了先验结构。

我们构建了这些网络的 SENet 等价版本，即 SE-Inception-ResNet-v2 和 SE-ResNeXt（ SE-ResNeXt-50 的配置见表 1）。表 2 的结果表明，将 SE 模块块引入这两种架构后，性能有显著提升。特别是，SE-ResNeXt-50 的 top-5 错误率为 5.49%，优于其直接对比模型 ResNeXt-50（top-5 错误率为 5.90%）以及更深的 ResNeXt-101（top-5 错误率为 5.57%）；而 ResNeXt-101 的参数量几乎是后者的两倍，计算开销也更大。至于 Inception-ResNet-v2 的实验，我们推测裁剪策略的差异可能导致其报告结果与我们重新实现的结果之间存在差距，因为原始图像尺寸在 [42] 中并未明确说明，而我们是从相对较大的图像中裁剪 299×299 区域（其中较短的边被调整大小）至 352 页)。SE-Inception-ResNet-v2（Top-5 错误率 4.79%）优于我们重新实现的 Inception-ResNet-v2（Top-5 错误率 5.21%），相对提升 0.42%（相对改善 8.1%），同时也优于 [42] 中报告的成果。

我们还在非残差网络中评估 SE 模块块的效果，通过采用 VGG-16 [39] 和 BN-Inception 架构 [16] 进行实验。由于深度网络难以优化 [16, 39], , 为便于从头训练 VGG-16，我们在每个卷积层后添加了一个批归一化层。我们采用相同的方案来训练 SE-VGG-16。比较结果如表 2 所示，显示出在残差架构中出现的相同现象。

最后，我们在表 3 中评估了两个具有代表性的轻量级架构：MobileNet [13] 和 ShuffleNet [52]，结果表明，SE 模块块能够在计算成本仅小幅增加的情况下，显著提升精度。这些实验证明，由 SE 模块块带来的改进可与多种架构结合使用。此外，该结论同样适用于残差和非残差基础结构。

	Top-1 错误率	前 5 个错误率
Places-365-CNN [37]	41.07	11.48
ResNet-152（ours）	41.15	11.61
SE-ResNet-152	**40.37**	**11.01**

表 5：Places365 验证集上的单作物错误率（%）。

ILSVRC 2017 分类竞赛结果。SENet 构成了我们参赛提交的基础，我们因此获得了第一名。我们的获胜模型由一组小型 SENet 组成，采用标准的多尺度与多裁剪融合策略，在测试集上实现了 2.251% 的 top-5 错误率。我们的高性能网络之一，称为 SENet-154，是通过将 SE 模块块与修改后的 ResNeXt[47]（详见补充材料）集成而构建的，其目标是在降低模型复杂度的同时追求最佳精度。我们在表 4 中将其与 ImageNet 验证集上表现最佳的已发表模型进行了对比。我们的模型在采用 224×224 中心裁剪评估时，top-1 错误率为 18.68%，top-5 错误率为 4.47%。为了进行公平比较，我们提供了 320×320 中心裁剪评估，结果显示相比先前工作有显著的性能提升。竞赛结束后，我们训练了一个具有更大输入尺寸 320×320 的 SENet-154，在 top-1（16.88%）和 top-5（3.58%）错误率指标下均取得了更低的错误率。

6.2. 场景分类

我们在 Places365-Challenge 数据集 [53] 上进行场景分类实验。该数据集包含 800 万张训练图像和 36,500 张验证图像，涵盖 365 个类别。与分类任务相比，场景理解任务能更好地评估模型泛化能力和抽象处理能力，因为它需要捕捉更复杂的数据关联，并对更大程度的外观变化具有更强的鲁棒性。

我们使用 ResNet-152 作为强基准来评估 SE 模块块的有效性，并遵循 [37] 中的训练和评估协议。表 5 展示了 ResNet-152 和 SE-ResNet-152 的结果。具体而言，SE-ResNet-152（前 5 类错误率为 11.01%）的验证错误率低于 ResNet-152（前 5 类错误率为 11.61%），这证明了 SE 模块块在不同数据集上表现良好。该 SENet 超越了在此任务上前期的最先进模型 Places-365-CNN [37]，其前 5 类错误率为 11.48%。

6.3. 在 COCO 上的目标检测

我们进一步使用 COCO 数据集 [25]（包含 8 万张训练图像和 4 万张验证图像）评估 SEblocks 在目标检测任务上的泛化能力，遵循 [10]。我们采用 Faster R-CNN [33] 作为检测算法，并遵循 [10] 中的基本实现。

	AP@IoU=0.5	AP
ResNet-50	45.2	25.1
SE-ResNet-50	46.8	26.4
ResNet-101	48.4	27.2
SE-ResNet-101	49.2	27.9

表 6：使用基础版 Faster R-CNN 在 COCO 40k 验证集上的目标检测结果。

此处我们的目的是评估用 SE-ResNet 替换基础架构 ResNet 所带来的收益，以便将改进归因于更优的特征表示。表 6 展示了在验证集上分别使用 ResNet-50、ResNet-101 及其 SE 对应版本的结果。SE-ResNet-50 在 COCO 标准指标 AP 上比 ResNet-50 高出 1.3%（相对提升 5.2%），在 AP@IoU=0.5 上高出 1.6%。重要的是，SE 模块块能够提升更深层的 ResNet-101 架构，在 AP 指标上带来 0.7% 的提升（相对提升 2.6%）。

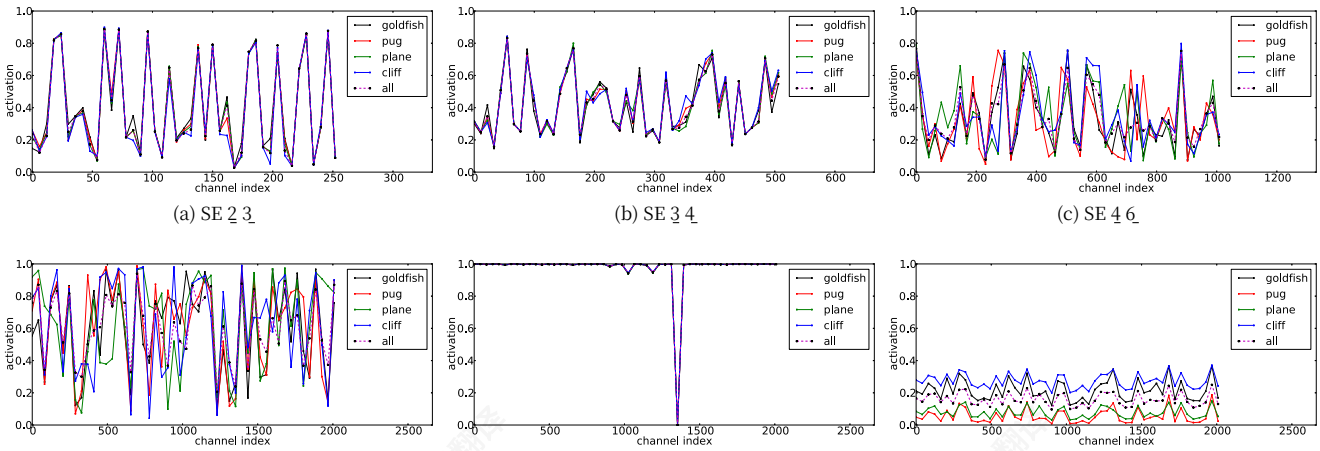
6.4. 分析与解释

缩放比例。公式 (5) 中引入的缩放比例 r 是一个重要的超参数，它允许我们调整模型中 SE 模块块的容量和计算成本。为了研究这种关系，我们基于 SE-ResNet-50 对不同 r 值进行了实验。表 7 的比较显示，性能并非随容量增加而单调提升。这可能是因为启用了 SE 模块块对训练集的通道间依赖关系进行了过拟合。特别是，我们发现设置 $r = 16$ 在精度和复杂度之间取得了良好的平衡，因此我们在所有实验中均使用了该值。

激励的作用。虽然 SE 模块块在经验上已被证明能提升网络性能，但我们也希望了解自门控激励机制在实际中是如何运作的。为了更清晰地描绘 SE 模块块的行为，在本节中，我们研究 SE-ResNet-50 模型中的示例激活，并考察其在不同块中相对于不同类别的分布。具体而言，我们从 ImageNet 数据集中采样四个类别，这些类别表现出语义和外观上的差异——

比例 r	Top-1 错误率	前 5 个错误率	百万参数
4	23.21	6.63	35.7
8	23.19	6.64	30.7
16	23.29	6.62	28.1
32	23.40	6.77	26.9
原始	24.80	7.48	25.6

表 7：SE-ResNet-50 在不同压缩比 r 下在 ImageNet 验证集上的单裁剪错误率（%）及参数量。其中 original 指 ResNet-50。



(a) SE 2 3 (b) SE 3 4 (c) SE 4 6

(d) SE 5 1 (e) SE 5 2 (f) SE 5 3

图 5：SE-ResNet-50 在 ImageNet 上不同模块中由激发引起的激活。模块命名为"SE stageID blockID"。

性，即金鱼、八哥、飞机和悬崖（这些类别的示例图像见补充材料）。随后，我们从验证集中为每个类别抽取 50 个样本，并计算每个阶段最后一个 SE 块中 50 个均匀采样通道的平均激活值（在采样下采样之前），并在图 5 中绘制其分布。作为参考，我们还绘制了所有 1000 个类别的平均激活值分布。

我们对激励的作用提出了以下三点观察。首先，在较低层（例如 SE 2 3），不同类别之间的分布几乎完全相同。这表明在网络的早期阶段，特征通道的重要性很可能由不同类别共享。然而，有趣的是，第二点观察是：随着网络深度增加，每个通道的值变得更具类别特异性，因为不同类别对特征的判别性价值表现出不同的偏好，例如 SE 4 6 和 SE 5 1。这两点观察与先前研究 [23, 50]，的发现一致，即较低层的特征通常更具通用性（即在分类语境下是类别无关的），而较高层的特征则具有更高的特异性。因此，SE 模块块通过自适应地促进特征提取和专业化，从而受益于表示学习，其专业化程度仅达到所需水平。最后，我们在网络的最后阶段观察到一些略有不同的现象。SE 5 2 表现出一种有趣的趋向饱和状态的趋势，其中大多数激活值接近 1，其余部分接近 0。当所有激活值都为 1 时，该块将退化为标准残差块。在 SE 5 3 （紧随全局池化之前，位于分类器之前）处，不同类别下也出现了类似的模式，仅存在轻微的尺度变化（该尺度可通过调分类器）。这表明 SE 5 2 和 SE_5_3 在提供网络重校准方面的重要性低于之前的模块块。这一发现与第 4 节中的实证调查结果一致，该结果表明，仅以微小的性能损失为代价，即可通过移除最后阶段的 SE 模块块显著减少总体参数数量。

7. 结论

本文提出了 SE 模块块，这是一种新颖的架构单元，旨在通过使网络能够执行动态通道级特征重校准来提升网络的表征能力。大量实验证明了 SENet 的有效性，其在多个数据集上均达到了最先进（state-of-the-art）的性能。此外，它们为理解先前架构在建模通道级特征依赖方面的局限性提供了一些见解，我们期望这些见解对其他需要强判别性特征的任务可能有所帮助。最后，SE 模块块所诱导的特征重要性可能对网络剪枝等压缩相关领域有所帮助。

致谢。我们要感谢 Andrew Zisserman 教授对本文提出的有益意见，感谢 Samuel Albanie 的讨论及写作修改。我们要感谢 Chao Li 在训练系统方面的贡献。Li Shen 受国家情报总监办公室（ODNI）和情报高级研究项目活动（IARPA）支持，合同编号为 2014-14071600010。本文所含观点及结论由作者提出，不应被视为 ODNI、IARPA 或美国政府正式政策或立场（无论明示或暗示）的必然代表。美国政府获准为政府目的复制和分发本出版物，尽管其上可能载有版权标注。

参考资料

[1] S. Bell, C. L. Zitnick, K. Bala, and R. Girshick. Inside-outside net: Detecting objects in context with skip pooling and recurrent neural networks. In *CVPR*, 2016. 1

[2] T. Bluche. Joint line segmentation and transcription for end-to-end handwritten paragraph recognition. In *NIPS*, 2016. 2

[3] C. Cao, X. Liu, Y. Yang, Y. Yu, J. Wang, Z. Wang, Y. Huang, L. Wang, C. Huang, W. Xu, D. Ramanan, and T. S. Huang. Look and think twice: Capturing top-down visual attention with feedback convolutional neural networks. In *ICCV*, 2015. 2

[4] L. Chen, H. Zhang, J. Xiao, L. Nie, J. Shao, W. Liu, and T. Chua. SCA-CNN: Spatial and channel-wise attention in convolutional networks for image captioning. In *CVPR*, 2017. 2

[5] Y. Chen, J. Li, H. Xiao, X. Jin, S. Yan, and J. Feng. Dual path networks. In *NIPS*, 2017. 2, 6

[6] F. Chollet. Xception: Deep learning with depthwise separable convolutions. In *CVPR*, 2017. 2

[7] J. S. Chung, A. Senior, O. Vinyals, and A. Zisserman. Lip reading sentences in the wild. In *CVPR*, 2017. 2

[8] D. Han, J. Kim, and J. Kim. Deep pyramidal residual networks. In *CVPR*, 2017. 6

[9] K. He, X. Zhang, S. Ren, and J. Sun. Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. In *ICCV*, 2015. 5

[10] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *CVPR*, 2016. 2, 5, 6, 7

[11] K. He, X. Zhang, S. Ren, and J. Sun. Identity mappings in deep residual networks. In *ECCV*, 2016. 2, 6

[12] S. Hochreiter and J. Schmidhuber. Long short-term memory. *Neural computation*, 1997. 2

[13] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam. Mobilenets: Efficient convolutional neural networks for mobile vision applications. *arXiv:1704.04861*, 2017. 3, 6

[14] G. Huang, Z. Liu, K. Q. Weinberger, and L. Maaten. Densely connected convolutional networks. In *CVPR*, 2017. 2, 6

[15] Y. Ioannou, D. Robertson, R. Cipolla, and A. Criminisi. Deep roots: Improving CNN efficiency with hierarchical filter groups. In *CVPR*, 2017. 2

[16] S. Ioffe and C. Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *ICML*, 2015. 1, 2, 5, 6

[17] L. Itti and C. Koch. Computational modelling of visual attention. *Nature reviews neuroscience*, 2001. 2

[18] L. Itti, C. Koch, and E. Niebur. A model of saliency-based visual attention for rapid scene analysis. *IEEE TPAMI*, 1998. 2

[19] M. Jaderberg, K. Simonyan, A. Zisserman, and K. Kavukcuoglu. Spatial transformer networks. In *NIPS*, 2015. 1, 2

[20] M. Jaderberg, A. Vedaldi, and A. Zisserman. Speeding up convolutional neural networks with low rank expansions. In *BMVC*, 2014. 2

[21] A. Krizhevsky, I. Sutskever, and G. E. Hinton. ImageNet classification with deep convolutional neural networks. In *NIPS*, 2012. 1, 3

[22] H. Larochelle and G. E. Hinton. Learning to combine foveal glimpses with a third-order boltzmann machine. In *NIPS*, 2010. 2

[23] H. Lee, R. Grosse, R. Ranganath, and A. Y. Ng. Convolutional deep belief networks for scalable unsupervised learning of hierarchical representations. In *ICML*, 2009. 8

[24] M. Lin, Q. Chen, and S. Yan. Network in network. *arXiv:1312.4400*, 2013. 2

[25] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollar, and C. L. Zitnick. Microsoft coco: Common objects in context. *ECCV*, 2014. 7

[26] H. Liu, K. Simonyan, O. Vinyals, C. Fernando, and K. Kavukcuoglu. Hierarchical representations for efficient architecture search. *arXiv: 1711.00436*, 2017. 2

[27] J. Long, E. Shelhamer, and T. Darrell. Fully convolutional networks for semantic segmentation. In *CVPR*, 2015. 1

[28] A. Miech, I. Laptev, and J. Sivic. Learnable pooling with context gating for video classification. *arXiv:1706.06905*, 2017. 2

[29] V. Mnih, N. Heess, A. Graves, and K. Kavukcuoglu. Recurrent models of visual attention. In *NIPS*, 2014. 2

[30] V. Nair and G. E. Hinton. Rectified linear units improve restricted boltzmann machines. In *ICML*, 2010. 3

[31] A. Newell, K. Yang, and J. Deng. Stacked hourglass networks for human pose estimation. In *ECCV*, 2016. 1, 2

[32] B. A. Olshausen, C. H. Anderson, and D. C. V. Essen. A neurobiological model of visual attention and invariant pattern recognition based on dynamic routing of information. *Journal of Neuroscience*, 1993. 2

[33] S. Ren, K. He, R. Girshick, and J. Sun. Faster R-CNN: Towards real-time object detection with region proposal networks. In *NIPS*, 2015. 1, 7

[34] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei. ImageNet large scale visual recognition challenge. *IJCV*, 2015. 2

[35] J. Sanchez, F. Perronnin, T. Mensink, and J. Verbeek. Image classification with the fisher vector: Theory and practice. *RR-8209, INRIA*, 2013. 3

[36] L. Shen, Z. Lin, and Q. Huang. Relay backpropagation for effective learning of deep convolutional neural networks. In *ECCV*, 2016. 4

[37] L. Shen, Z. Lin, G. Sun, and J. Hu. Places401 and places365 models. https://github.com/lishen-shirley/Places2-CNNs, 2016. 7

[38] L. Shen, G. Sun, Q. Huang, S. Wang, Z. Lin, and E. Wu. Multi-level discriminative dictionary learning with application to large scale image classification. *IEEE TIP*, 2015. 3

[39] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. In *ICLR*, 2015. 2, 3, 5, 6

[40] R. K. Srivastava, K. Greff, and J. Schmidhuber. Training very deep networks. In *NIPS*, 2015. 2

[41] M. F. Stollenga, J. Masci, F. Gomez, and J. Schmidhuber. Deep networks with internal selective attention through feedback connections. In *NIPS*, 2014. 2

[42] C. Szegedy, S. Ioffe, V. Vanhoucke, and A. Alemi. Inception-v4, inception-resnet and the impact of residual connections on learning. In *ICLR Workshop*, 2016. 2, 3, 4, 5, 6

[43] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich. Going deeper with convolutions. In *CVPR*, 2015. 1, 2, 4

[44] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna. Rethinking the inception architecture for computer vision. In

CVPR, 2016. 2, 6

[45] A. Toshev and C. Szegedy. DeepPose: Human pose estimation via deep neural networks. In *CVPR*, 2014. 1

[46] F. Wang, M. Jiang, C. Qian, S. Yang, C. Li, H. Zhang, X. Wang, and X. Tang. Residual attention network for image classification. In *CVPR*, 2017. 2, 6

[47] S. Xie, R. Girshick, P. Dollar, Z. Tu, and K. He. Aggregated residual transformations for deep neural networks. In *CVPR*, 2017. 2, 3, 5, 6, 7

[48] K. Xu, J. Ba, R. Kiros, K. Cho, A. Courville, R. Salakhudinov, R. Zemel, and Y. Bengio. Show, attend and tell: Neural image caption generation with visual attention. In *ICML*, 2015. 2

[49] J. Yang, K. Yu, Y. Gong, and T. Huang. Linear spatial pyramid matching using sparse coding for image classification. In *CVPR*, 2009. 3

[50] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson. How transferable are features in deep neural networks? In *NIPS*, 2014. 8

[51] X. Zhang, Z. Li, C. C. Loy, and D. Lin. Polynet: A pursuit of structural diversity in very deep networks. In *CVPR*, 2017. 6

[52] X. Zhang, X. Zhou, M. Lin, and J. Sun. Shufflenet: An extremely efficient convolutional neural network for mobile devices. *arXiv:1707.01083*, 2017. 3, 6

[53] B. Zhou, A. Lapedriza, A. Khosla, A. Oliva, and A. Torralba. Places: A 10 million image database for scene recognition. *IEEE TPAMI*, 2017. 7

[54] B. Zoph and Q. V. Le. Neural architecture search with reinforcement learning. In *ICLR*, 2017. 2

[55] B. Zoph, V. Vasudevan, J. Shlens, and Q. V. Le. Learning transferable architectures for scalable image recognition. *arXiv: 1707.07012*, 2017. 2, 6